

Análisis profundo de características en una transferencia basada en aprendizaje Enfoque para la Identificación Automática de Edema macular diabético

Joaquín de Moura

*CITIC-Centro de Investigación de la Información
y Tecnologías de la Comunicación*
Universidad de A Coruña
La Coruña, España
joaquim.demoura@udc.es

Jorge Nuevo

*CITIC-Centro de Investigación de la Información
y Tecnologías de la Comunicación*
Universidad de A Coruña
La Coruña, España
jnov@udc.es

marcos ortega

*CITIC-Centro de Investigación de la Información
y Tecnologías de la Comunicación*
Universidad de A Coruña
La Coruña, España
mortega@udc.es

Abstracto—El edema macular diabético (EMD) es una de las causas más comunes de discapacidad visual y ceguera en personas con diabetes. Entre las diferentes modalidades de imagen, la Tomografía de Coherencia Óptica (OCT) es una técnica de imagen oftalmológica no invasiva que se utiliza habitualmente para el diagnóstico, seguimiento y tratamiento del EMD. En este contexto, este artículo propone una nueva metodología para la clasificación automática de DME utilizando imágenes OCT. En primer lugar, el método extrae un conjunto de características profundas de las imágenes OCT de destino mediante un enfoque basado en el aprendizaje por transferencia. Luego, se selecciona el subconjunto más relevante de características profundas utilizando diferentes estrategias de selección de características. Finalmente, se aplica un enfoque de aprendizaje automático para probar el potencial del método implementado. La metodología propuesta se validó utilizando un conjunto de datos de imágenes OCT recuperadas de 400 pacientes diferentes, siendo 200 con EMD y 200 casos normales. El sistema propuesto logró resultados satisfactorios, alcanzando una mejor precisión del 97,50%, utilizando solo el 14,65% de las características profundas en la clasificación de esta patología ocular, demostrando además su desempeño competitivo con respecto a otros enfoques del estado del arte. .

YO YONTRODUCCIÓN

Se estima que 253 millones de personas sufren de discapacidad visual en todo el mundo y aproximadamente 350 millones de personas viven actualmente con diabetes. Además, se espera que estas cifras se dupliquen entre 2005 y 2030, según las directrices de la Organización Mundial de la Salud (OMS) [1]. El Edema Macular Diabético (EMD) es una de las causas más frecuentes de discapacidad visual y ceguera asociada a la diabetes en los países desarrollados [2], representando un problema de salud pública preocupante. Esta enfermedad se caracteriza por un engrosamiento anormal de la retina en el área macular causado por la fuga y acumulación de líquido intrarretiniano [3] en las capas plexiformes interna y externa del fondo de ojo [4].

Este trabajo cuenta con el apoyo del Instituto de Salud Carlos III, Gobierno de España y fondos FEDER de la Unión Europea a través de los proyectos de investigación DTS18/00136 y del Ministerio de Economía y Competitividad, Gobierno de España a través del proyecto de investigación DPI2015-69948-R. Además, este trabajo ha recibido el apoyo financiero de la Unión Europea (Fondo Europeo de Desarrollo Regional - FEDER) y la acreditación Xunta de Galicia, Centro singular de investigación de Galicia 2016-2019, Ref. ED431G/01; y Grupos de Referencia Competitiva, Ref. ED431C 2016-047.

El diagnóstico asistido por computadora (CAD) se ha convertido en un importante tema de investigación en los últimos años [5]. Estos sistemas de apoyo a la decisión clínica son ampliamente utilizados por especialistas clínicos en el análisis de diferentes enfermedades sistémicas y oculares [6]. La tomografía de coherencia óptica (OCT) es una técnica de imagen médica no invasiva que se usa comúnmente en el diagnóstico y tratamiento de muchos trastornos de la retina en la rutina de la práctica oftalmológica. Esta técnica ofrece imágenes de alta resolución de los tejidos de la retina sin contacto que pueden ser utilizadas para la detección temprana de diferentes enfermedades oculares como, por ejemplo, glaucoma [7], Degeneración Macular Asociada a la Edad (DMAE) [8], epirretiniana membrana [9], oclusiones vasculares [10] o DME [11]. Específicamente, la Figura 1 muestra ejemplos representativos de imágenes OCT con y sin la enfermedad DME,

En la actualidad, la identificación, diagnóstico y seguimiento de la enfermedad del EMD se realiza mediante el análisis visual de imágenes OCT. Este análisis visual no solo es un procedimiento tedioso y lento, sino que también es propenso a la subjetividad de los especialistas clínicos. Por esa razón, un sistema completamente automático para la clasificación de imágenes OCT entre casos normales o DME es de gran ayuda, reduciendo significativamente la carga de trabajo. Al mismo tiempo, ofrece una identificación más precisa sobre posibles cambios estructurales o morfológicos anormales en los tejidos de la retina, reduciendo la subjetividad de los expertos clínicos y mejorando la calidad del diagnóstico y tratamiento del paciente.

En los últimos años se han presentado algunas propuestas computacionales relacionadas con el análisis DME utilizando imágenes OCT. Como referencia, Alsaihet *et al.* [12] propuso una metodología para identificar los volúmenes de DME frente a los de OCT normales utilizando solo características de patrones binarios locales (LBP) y un clasificador de máquina de vectores de soporte (SVM). Srinivasan *et al.* [13] propusieron un sistema automático para la clasificación de volúmenes OCT como normales, AMD o DME utilizando descriptores Histogram of Oriented Gradients (HOG) y un modelo de aprendizaje SVM para clasificar




Figura 1. Ejemplos representativos de imágenes OCT.1 California, imágenes OCT sin presencia de DME.2 Dakota del Norte, imágenes OCT con presencia de DME.

cada imagen OCT. Del mismo modo, Wang *et al.*[14] propuso un sistema para discriminar AMD, DME y mácula sana utilizando características basadas en el patrón de configuración lineal (LCP). Luego, se seleccionó el conjunto de características más relevante mediante el algoritmo de selección de características basado en la correlación (CFS). Finalmente, se utilizó el algoritmo Sequential Minimal Optimization (SMO) en el proceso de clasificación. En la obra de Hussain *et al.*[15], los autores propusieron una metodología que utiliza el clasificador Random Forest (RF) y un conjunto de características retinianas como el grosor retiniano, el grosor de cada capa retiniana así como el volumen de las diferentes estructuras patológicas como drusas e hiperretina. -focos reflectantes.

Recientemente, las estrategias basadas en el aprendizaje profundo se han utilizado con éxito para la clasificación de imágenes OCT como DME o casos normales. Carri *et al.*[16] propusieron un sistema automático que utiliza una Red Neural Convocional (CNN), en particular, el modelo GoogLeNet pre-entrenado, para la identificación de DME, AMD o no patología en imágenes OCT. En la obra de Awais *et al.*[17], los autores propusieron un sistema para la clasificación de imágenes DME y OCT normales. El sistema usó el modelo VGG-16 preentrenado para la extracción profunda de características y dos enfoques diferentes de aprendizaje automático, k-Nearest Neighbors (k-NN) y Decision Tree (DT), para el proceso de clasificación. En otra propuesta, Chan *et al.*[18] propusieron un sistema para la detección de DME utilizando imágenes OCT. Para ello se extraen características profundas utilizando el modelo AlexNet, siendo las imágenes OCT clasificadas mediante una SVM.

Como podemos ver, la presente literatura siguió diferentes estrategias de aprendizaje, obteniendo resultados satisfactorios en su mayoría utilizando enfoques de aprendizaje profundo. Sin embargo, estos enfoques presentan algunas limitaciones intrínsecas de los modelos CNN. En particular, los sistemas propuestos requieren conjuntos de datos masivos y

capacidad informática para llevar a cabo el paso de retropropagación computacionalmente costoso y lograr un rendimiento adecuado. Además, dada la significativamente alta dimensionalidad de las capas de los modelos CNN, los enfoques propuestos carecen de un análisis exhaustivo centrado en el comportamiento de las características profundas extraídas. Este análisis es necesario para determinar el subconjunto más relevante de características profundas que maximiza la separabilidad entre diferentes clases y, por lo tanto, optimiza la estrategia de aprendizaje al reducir la dimensionalidad del problema.

En este trabajo, proponemos un sistema completamente automático para la clasificación de imágenes DME y OCT normales. Para lograr esto, se utiliza un enfoque basado en el aprendizaje de transferencia, que reduce el requisito de computación, para la extracción profunda de características de diferentes capas totalmente conectadas y diferentes modelos de CNN pre-entrenados, que se combinan con un análisis exhaustivo de diferentes métodos de selección de características. De esta forma, determinamos el subconjunto óptimo de rasgos profundos que caracterizan mejor el problema, reduciendo su dimensionalidad y facilitando el proceso de aprendizaje. Finalmente, se utiliza un enfoque de aprendizaje automático para entrenar y probar el potencial de las características profundas identificadas del método implementado.

Este documento está organizado de la siguiente manera: la Sección 2 describe la metodología del sistema propuesto. Los resultados y discusiones se presentan y discuten en la Sección 3. Finalmente, la Sección 4 muestra las conclusiones así como las posibles líneas de trabajo futuras.

II. METODOLOGÍA

Como entrada, la metodología propuesta recibe una imagen OCT. La metodología se compone de un conjunto de pasos progresivos para la clasificación de imágenes OCT entre casos normales y DME. En primer lugar, como se ha dicho, el sistema extrae un conjunto de

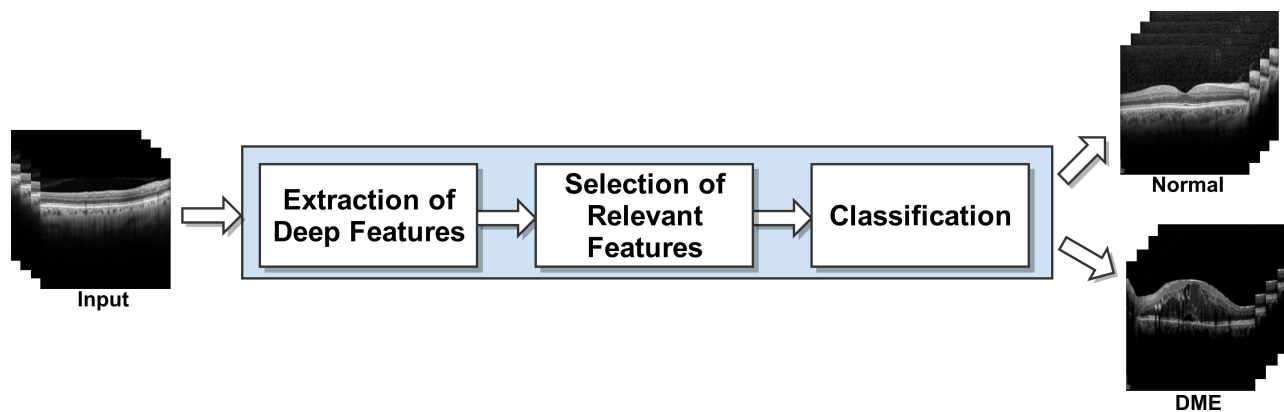


Figura 2. Principales pasos de la metodología propuesta.

características profundas de las imágenes OCT utilizando un enfoque basado en el aprendizaje de transferencia utilizando diferentes capas totalmente conectadas y también de diferentes modelos de CNN pre-entrenados. Luego, el sistema identifica el subconjunto más relevante de características profundas utilizando diferentes métodos de selección de características. Luego, se aplica una estrategia de aprendizaje automático para generar un modelo de clasificación. Finalmente, el sistema presenta como salida una imagen OCT etiquetada con la identificación precisa de pacientes con EMD y sujetos normales. Cada uno de estos pasos se discutirá a continuación. Una representación esquemática de los principales pasos de esta metodología se puede ver en la Figura 2.

A. Extracción de características profundas

Los modelos CNN son particularmente adecuados para encontrar patrones en imágenes. Estas redes utilizan una arquitectura específica que está bien adaptada para extraer características profundas y clasificar datos de alta dimensionalidad [19]. De esta forma, se integraron y analizaron tres modelos de CNN pre-entrenados bien conocidos para el proceso de extracción de características profundas, dada su relativa idoneidad y resultados adecuados para este problema. En particular, estos modelos de CNN son AlexNet, VGG-19 e Inception-V3. Además, con el fin de obtener un análisis más exhaustivo y mejorar el rendimiento del método, analizamos diferentes capas totalmente conectadas de cada una de las arquitecturas de red mencionadas. Los preámbulos de las arquitecturas CNN y sus correspondientes capas completamente conectadas se explican a continuación:

1) *Modelo AlexNet*, preentrenado con imágenes de ImageNet, es una estrategia de aprendizaje profundo simple y eficiente. Este modelo fue propuesto por Krizhevsky et al. [20] y se aplicó con éxito a problemas de clasificación de imágenes a gran escala [21]. La arquitectura de AlexNet se compone de diferentes capas en cascada: capas de convolución, capas de agrupación, capas de unidad lineal rectificadas (ReLU) y 3 capas totalmente conectadas (a saber, FC6, FC7 y FC8, con una dimensionalidad de 4096, 4096 y 1000 características, respectivamente).

2) *Modelo VGG-19* es una red convolucional que fue entrenada en más de un millón de imágenes del conjunto de datos de ImageNet [22]. Este modelo tiene poderosas capacidades de aprendizaje, lo que permite que la red extraiga una información más

conjunto completo de características profundas. La arquitectura VGG-19 consta de 19 capas de peso, incluidas 16 capas convolucionales y 3 capas totalmente conectadas (también conocidas como FC6, FC7 y FC8, que incluyen funciones 4096, 4096 y 1000, respectivamente).

3) *Modelo Inception-V3*, también preentrenado con imágenes de ImageNet, es una evolución de la arquitectura de GoogLeNet [23]. Inception-V3 se compone de 48 capas profundas y consta de múltiples capas de agrupación y convolucionales cuyas salidas están concatenadas. En este trabajo, usamos la última capa completamente conectada del modelo Inception-V3 (es decir, Predicciones, con una dimensión de 1000 características)

como extractor de características profundas.

B. Selección de características relevantes

El desempeño de los modelos de aprendizaje generalmente depende de la elección del subconjunto de características que maximiza la separabilidad entre diferentes clases [24]. Si el subconjunto de características contiene información irrelevante, los algoritmos de aprendizaje pueden producir resultados menos precisos y menos comprensibles, así como la correspondiente penalización en términos de costos computacionales [25]. Por esa razón, el conjunto de características profundas previamente definido se analizó utilizando tres selectores de características diferentes: Selección de características basada en correlación (CFS), Relief y Selección de características de agrupación basada en aprendizaje local (LLCFS). Cada uno de estos selectores de funciones se explica con más detalle a continuación:

1) *SFCL* La estrategia asume que el conjunto de características más relevante contiene características discriminatorias que son predictivas de la clase pero que no están correlacionadas entre sí [26], como Eq. 1 establece:

$$r_{zc} = \sqrt{\frac{kT_z \bar{r}}{k + k(k-1)r_{yo}}} \quad (1)$$

dónde k representa el número de características, $r_{z\bar{z}}$ representa el promedio de las correlaciones entre el conjunto de características y la variable categórica r_{yo} representa la intercorrelación promedio entre las características. Además, CFS es un método basado en filtros y, como tal, no conlleva un alto costo computacional debido a la aplicación repetida del algoritmo de aprendizaje.




Fig. 3. Evolución de la precisión utilizando todos los subconjuntos de características profundas que se extrajeron de las diferentes redes analizadas en las capas FC8/FC-Predictions totalmente conectadas y proporcionadas por cada método selector de características.

2) *RelieveF* el selector de funciones es una extensión del algoritmo Relief [27]. Esta estrategia, una de las más populares, estima la calidad de las características en función de lo bien que sus valores distinguen entre las instancias que se encuentran próximas entre sí, apreciando así su efecto sinérgico [28]. Para ello, el método estima la relevancia de cada característica utilizando la diferencia de probabilidades. De esta manera, la relevancia de atributo A se define, de acuerdo con la Ec. 2:

$$r(A) = \text{PAG}(Z/C) - \text{PAG}(Z/D) \quad (2)$$

dónde Z representa un valor diferente del atributo A , C es la instancia más cercana de una clase diferente y D indica la instancia más cercana de una misma clase.

3) *LLCFS* la selección de características obtiene una representación adecuada del conjunto de datos a través del aprendizaje del núcleo en el marco de la agrupación en clústeres basada en el aprendizaje local (LLC) [29]. Específicamente, este enfoque asocia un peso a cada función o kernel, incluyéndolo en la regularización integrada del algoritmo LLC para tener en cuenta la relevancia de cada función o kernel. A esto final, el método utiliza la función discriminante local $F(x)$ para realizar la selección de características:

$$F(A) = A w c + b c_i \quad (3)$$

dónde w representa el coeficiente de regresión y $b c_i$ indica el término de sesgo de la i -ésima característica A dividido en el clúster C .

C. Clasificación

Usando el subconjunto de las características profundas más relevantes, se utilizó un clasificador representativo para probar su potencial en el enfoque propuesto. En particular, usamos el clasificador SVM [30]. Las SVM se basan en el principio de encontrar el hiperplano de margen máximo que mejor discrimine las dos clases [31].

Para ello, el algoritmo utiliza una máquina de decisión de núcleo disperso que evita el cálculo de probabilidades posteriores al construir su modelo de aprendizaje. De esta manera, probamos el potencial de discriminación de todos los subconjuntos de características profundas óptimos identificados de las diferentes redes analizadas y capas completamente conectadas que fueron proporcionadas por las estrategias de selección utilizadas.

tercero RESULTADOS Y DISCUSIÓN

La metodología se probó con 400 imágenes de OCT centradas en la mácula y tomadas de ambos ojos, izquierdo y derecho, siendo 200 con DME y 200 casos normales. Estas imágenes fueron adquiridas con un oftalmoscopio láser de barrido confocal, un Spectralis® Modelo OCT de Heidelberg Engineering, con una resolución de 2032×596 píxeles. Este dispositivo de captura representa uno de los más utilizados por los servicios de oftalmología. Se representaron diferentes niveles de intensidad y contraste en el conjunto de datos de imágenes. Este estudio fue diseñado como una declaración de principios éticos para la investigación médica y siguiendo los principios de la Declaración de Helsinki.

El conjunto de datos inicial fue etiquetado por un clínico experto, identificando casos con presencia de DME y casos normales. Este conjunto de datos se dividió aleatoriamente en dos conjuntos de datos más pequeños, con el 70 % de los casos para entrenamiento y el 30 % para pruebas. El paso de clasificación se realizó mediante una validación cruzada de 10 veces con 5 repeticiones, calculándose la precisión media para ilustrar el rendimiento general del sistema propuesto.

En este trabajo se repitieron todos los experimentos propuestos utilizando diferentes configuraciones: modelos de aprendizaje profundo AlexNet, VGG-19 e Inception-V3; Selectores de funciones CFS, ReliefF y LLCFS; y capas totalmente conectadas FC6, FC7, FC8 y Predictions. Además, estructuramos los resultados de estos experimentos agrupándolos según las diferentes capas totalmente conectadas.

En primer lugar, filtramos el subconjunto óptimo de características profundas que discriminan mejor la presencia de DME en las imágenes OCT mediante la aplicación y el análisis de diferentes selectores de características. En particular, usamos el valor predeterminado de la relevancia de la característica

por las capas menos profundas, como FC6, puede distinguir mejor las características globales de las imágenes OCT y la condición patológica analizada, mientras que las características que aprenden las capas posteriores, como FC7, FC8 y Predictions, son menos expresivas en el contexto de la representación DME, pero la precisión de la clasificación solo disminuyó ligeramente.

Comparamos la metodología propuesta con los métodos más representativos del estado del arte en este número. Estos métodos fueron previamente introducidos y descritos en la Sección I. Por lo tanto, la Tabla VII presenta los mejores resultados de precisión de los métodos del estado del arte y nuestra propuesta. A pesar de que se probaron muchos enfoques con diferentes conjuntos de datos de imágenes y en diferentes condiciones (tamaño de imagen, resolución a nivel de píxel, dispositivos OCT, etc.), nuestro método ofrece un rendimiento competitivo, superando al resto de los enfoques.

En este artículo, proponemos una metodología completa para la clasificación automática de imágenes DME y OCT normales. El DME es una de las causas más comunes de pérdida de la visión entre las personas con diabetes y representa un problema de salud pública preocupante. Afrontamos el problema con una estrategia óptima y precisa, mediante el análisis de características profundas que se extraen mediante un enfoque basado en el aprendizaje de transferencia, que reduce los requisitos informáticos, desde diferentes capas totalmente conectadas (FC6, FC7, FC8 y Predicciones, incluidas 4096, 4096, 1000 y 1000 funciones profundas respectivamente) y también de diferentes modelos de CNN preentrenados (AlexNet, VGG-19 e Inception-V3). Cada subconjunto de características profundas se analizó para optimizar el método propuesto, reduciendo la dimensionalidad del problema utilizando tres selectores de características diferentes (CFS, ReliefF y LLCFS). Y finalmente, Utilizando el subconjunto más relevante de características profundas, se entrenó un clasificador SVM para probar el potencial del enfoque implementado. Una vez entrenado, el sistema propuesto puede identificar con precisión la presencia del DME en tiempo real y sin ninguna configuración adicional.

La validación del método propuesto se realizó utilizando 400 imágenes de OCT de diferentes pacientes, etiquetadas por un experto clínico. A pesar de la complejidad de esta patología ocular, el sistema propuesto obtuvo resultados satisfactorios con el conjunto de datos considerado, alcanzando un 97.50% de precisión media de la prueba, utilizando solo un 14.65% de las características profundas de la capa correspondiente. Dado eso, los mejores resultados de configuración se obtuvieron de la capa FC6 totalmente conectada del modelo VGG-19 preentrenado usando el selector de funciones LLCFS. En consecuencia, el sistema propuesto ha demostrado ser lo suficientemente robusto como para ser utilizado en la práctica clínica diaria, ayudando a los médicos a producir un diagnóstico más preciso y tratamientos adecuados.

Como trabajo futuro, se puede realizar un análisis adicional y la inclusión de una gama más amplia de clasificadores. Aprovechando la viabilidad del método diseñado, podría adaptarse para afrontar otras patologías oculares relevantes, como la membrana epirretiniana, las oclusiones vasculares o la DMAE, entre otras. Además, tenemos previsto estudiar la posibilidad de ampliar el dominio de la metodología a otros dispositivos de captura OCT.

Complementariamente, las Tablas IV, V y VI presentan los resultados de desempeño de las pruebas que fueron obtenidos por cada modelo de aprendizaje. En general, los resultados están en línea con el rendimiento del entrenamiento, siendo el método propuesto capaz de clasificar satisfactoriamente imágenes DME y OCT normales. En particular, como podemos ver en la Tabla IV, los mejores resultados de precisión se obtuvieron utilizando la capa FC6 totalmente conectada con el modelo VGG-19 combinado con el selector de funciones LLCFS, arrojando un rendimiento del 97,50 % utilizando solo el 14,65 % de los datos extraídos. Características profundas de esa capa. Con respecto al análisis de FC7 y FC8/ Predicciones, ambos también ofrecieron un desempeño adecuado, alcanzando valores de precisión de 96,67% y 95,00%, respectivamente, reforzando así la validez del método propuesto. Esto puede explicarse por el hecho de que las características que se aprendieron




Fig. 4. Evolución de la precisión utilizando los subconjuntos progresivos de características profundas que se extrajeron de la capa FC6 completamente conectada y proporcionadas por cada método de selección de características. (a) Resultados de precisión que se obtuvieron con el modelo AlexNet. (b) Resultados de precisión que se obtuvieron con el modelo VGG-19.




Fig. 5. Evolución de la precisión utilizando los subconjuntos progresivos de características profundas que se extrajeron de la capa FC7 completamente conectada y proporcionadas por cada método de selección de características. (a) Resultados de precisión que se obtuvieron con el modelo AlexNet. (b) Resultados de precisión que se obtuvieron con el modelo VGG-19.

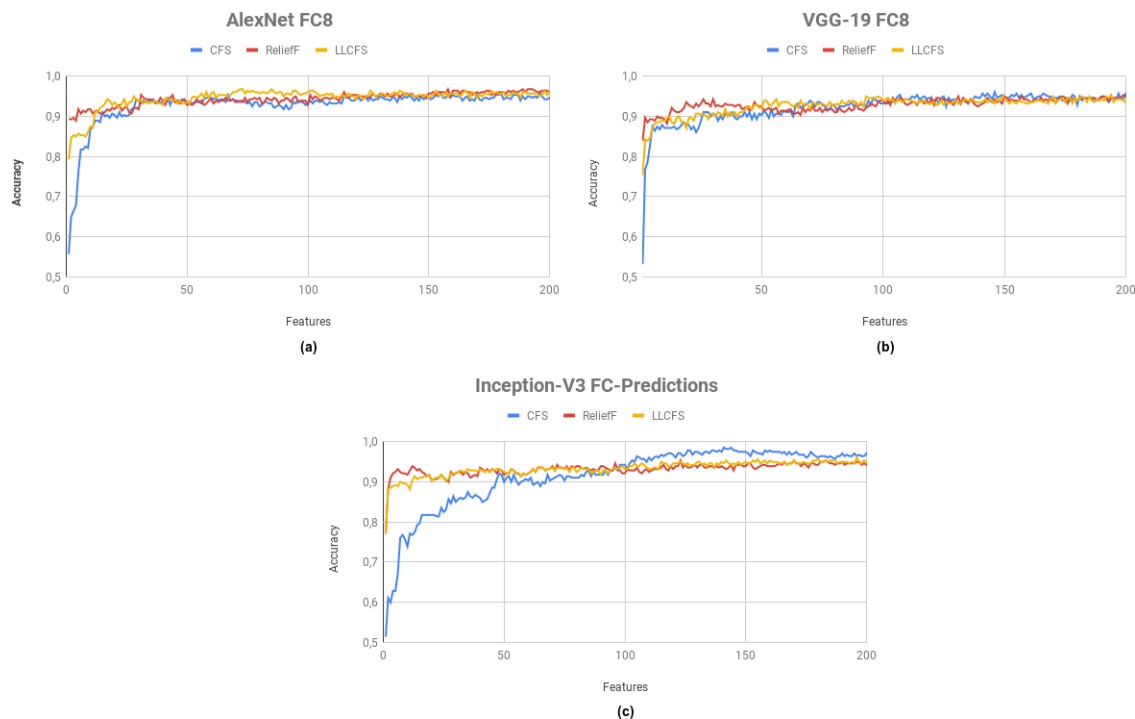


Fig. 6. Evolución de la precisión utilizando los subconjuntos progresivos de características profundas que se extrajeron de las capas FC8/FC-Predictions completamente conectadas y proporcionadas por cada método de selección de características. (a) Resultados de precisión que se obtuvieron con el modelo AlexNet. (b) Resultados de precisión que se obtuvieron con el modelo VGG-19. (c) Resultados de precisión que se obtuvieron con el modelo Inception-V3.

TABLA I

RESULTADOS DE PRECISIÓN OBTENIDOS EN LA ETAPA DE ENTRENAMIENTO POR CADA MODELO CON EL SUBCONJUNTO ÓPTIMO DE CARACTERÍSTICAS PROFUNDAS QUE SE EXTRAEN EN EL TOTALMENTE-CONECTADOFC6CAPA.

Profundo Modelo	FC6					
	Selector de características	norte de características	mín. Exactitud	máx. Exactitud	Precisión media	estándar Exactitud
AlexNet	SFC	3350	0.9679	0.9750	0.9707	0.0030
AlexNet	RelieveF	25	0.9643	0.9786	0.9714	0.0056
AlexNet	LLCFS	1650	0.9536	0.9714	0.9643	0.0071
VGG-19	SFC	256	0.9607	0.9643	0.9629	0.0020
VGG-19	RelieveF	131	0.9714	0.9883	0.9829	0.0089
VGG19	LLCFS	600	0.9536	0.9643	0.9607	0.0051

TABLA II

RESULTADOS DE PRECISIÓN OBTENIDOS EN LA ETAPA DE ENTRENAMIENTO POR CADA MODELO CON EL SUBCONJUNTO ÓPTIMO DE CARACTERÍSTICAS PROFUNDAS QUE SE EXTRAEN EN EL TOTALMENTE-CONECTADOFC7CAPA.

Profundo Modelo	FC7					
	Selector de características	norte de características	mín. Exactitud	máx. Exactitud	Precisión media	estándar Exactitud
AlexNet	SFC	1250	0.9607	0.9750	0.9707	0.0064
AlexNet	RelieveF	306	0.9607	0.9750	0.9714	0.0062
AlexNet	LLCFS	2800	0.9607	0.9714	0.9686	0.0047
VGG19	SFC	318	0.9750	0.9857	0.9800	0.0048
VGG-19	RelieveF	343	0.9500	0.9786	0.9707	0.0125
VGG-19	LLCFS	1100	0.9536	0.9786	0.9693	0.0096

TABLA III

RESULTADOS DE PRECISIÓN OBTENIDOS EN LA ETAPA DE ENTRENAMIENTO POR CADA MODELO CON EL SUBCONJUNTO ÓPTIMO DE CARACTERÍSTICAS PROFUNDAS QUE SE EXTRAEN EN EL TOTALMENTE-CONECTADOFC8/FC-PCAPAS DE REDICCIONES.

Profundo Modelo	FC8/FC-Predicciones					
	Selector de características	norte de características	mín. Exactitud	máx. Exactitud	Precisión media	estándar Exactitud
AlexNet	SFC	776	0.9500	0.9786	0.9671	0.0127
AlexNet	RelieveF	530	0.9607	0.9821	0.9721	0.0105
AlexNet	LLCFS	72	0.9393	0.9786	0.9636	0.0146
VGG-19	SFC	938	0.9679	0.9786	0.9743	0.0047
VGG-19	RelieveF	532	0.9571	0.9750	0.9693	0.0082
VGG-19	LLCFS	853	0.9607	0.9750	0.9693	0.0054
Inicio-V3	SFC	141	0.9786	0.9893	0.9843	0.0041
Inicio-V3	RelieveF	722	0.9643	0.9750	0.9700	0.0041
Inicio-V3	LLCFS	637	0.9643	0.9714	0.9671	0.0030

TABLA IV

PRECISIÓN EST OBTENIDA EN LA ETAPA DE PRUEBA POR CADA MODELO CON EL SUBCONJUNTO ÓPTIMO DE CARACTERÍSTICAS PROFUNDAS QUE SE EXTRAEN EN LA COMPLETAMENTE-CONECTADOFC6CAPA.

Profundo Modelo	FC6		
	Selector de características	% de características	Exactitud
AlexNet	SFC	81,79%	0.9583
AlexNet	RelieveF	0,61%	0.9167
AlexNet	LLCFS	40,28%	0.9500
VGG-19	SFC	6,25%	0.9583
VGG-19	RelieveF	3,20%	0.9583
VGG-19	LLCFS	14,65%	0.9750

TABLA V

PRECISIÓN EST OBTENIDA EN LA ETAPA DE PRUEBA POR CADA MODELO CON EL SUBCONJUNTO ÓPTIMO DE CARACTERÍSTICAS PROFUNDAS QUE SE EXTRAEN EN LA COMPLETAMENTE-CONECTADOFC7CAPA.

Profundo Modelo	FC7		
	Selector de características	% de características	Exactitud
AlexNet	SFC	30,52%	0.9167
AlexNet	RelieveF	7,47%	0.9167
AlexNet	LLCFS	68,36%	0.9333
VGG-19	SFC	7,76%	0.9333
VGG-19	RelieveF	8,37%	0.9667
VGG-19	LLCFS	26,86%	0.9667

REFERENCIAS

- [1] OMS. Discapacidad visual y ceguera. *Organización Mundial de la Salud*, 2017.
- [2] Rupert RA Bourne, Seth R Flaxman, Tasanee Braithwaite, Maria V Cicinelli, Aditi Das, Jost B Jonas, Jill Keefe, John H Kempen, Janet Leasher, Hans Limburg, et al. Magnitud, tendencias temporales y proyecciones de la prevalencia mundial de la ceguera y el deterioro de la visión de lejos y de cerca: una revisión sistemática y un metanálisis. *La salud global de Lancet*, 5(9):e888–e897, 2017.

- [3] Joaquim de Moura, Jorge Novo, José Rouco, Manuel G Penedo y Marcos Ortega. Identificación automática de regiones cistoideas intrarretinianas en tomografía de coherencia óptica. En *Conferencia sobre Inteligencia Artificial en Medicina en Europa*, páginas 305–315. Springer, 2017.
- [4] Edema macular diabético. *Oftalmológica*, 227 (Suplemento 1): 21–29, 2012.
- [5] Kunio Doi. Diagnóstico asistido por ordenador en imagen médica: revisión histórica, estado actual y potencial futuro. *Gráficos e imágenes médicas computarizadas*, 31(4-5):198–211, 2007.
- [6] Joaquim de Moura, Jorge Novo, Marcos Ortega, Noelia Barreira y

TABLA VI

BPRECISIÓN EST OBTENIDA EN LA ETAPA DE PRUEBA POR CADA MODELO CON EL SUBCONJUNTO ÓPTIMO DE CARACTERÍSTICAS PROFUNDAS QUE SE EXTRAEN EN LA COMPLETAMENTE-CONECTADO FC8/FC-PCAPAS DE REDICCIONES.

Modelo	FC8/FC-Predicciones		
	Selector de características	% de características	Exactitud
AlexNet	SFC	77,60%	0.9250
AlexNet	RelieveF	53,00%	0.9417
AlexNet	LLCFS	7,20%	0.9417
VGG-19	SFC	93,80%	0.9417
VGG-19	RelieveF	53,20%	0.9500
VGG-19	LLCFS	85,30%	0.9417
Inicio-V3	SFC	14,10%	0.9333
Inicio-V3	RelieveF	72,20%	0.9417
Inicio-V3	LLCFS	63,70%	0.9417

TABLA VII

EMDCLASIFICACIÓN COMPARATIVA DE DESEMPEÑO ENTRE DE LOS ESTADO-DE-EL-EL ARTE Y LA METODOLOGÍA PROPUESTA.

Lo último Métodos	Exactitud (%)
(karriet al., 2017) [16]	92,50%
(Awais et al., 2017) [17]	87,50%
(Chan et al., 2017) [18]	96,07%
(Hussein et al., 2018) [15]	97,33%
Método propuesto	97,50%

Manuel G Penedo. Extracción de árboles de vasos y estimación de profundidad con imágenes OCT. En *Conferencia de la Asociación Española de Inteligencia Artificial*, páginas 23–33. Springer, 2016.

- [7] Igor I Bussel, Gadi Wollstein y Joel S Schuman. OCT para diagnóstico de glaucoma, cribado y detección de la progresión del glaucoma. *Revista británica de oftalmología*, 98 (Suplemento 2): ii15–ii19, 2014.
- [8] Stephanie J Chiu, Joseph A Izatt, Rachelle V O'Connell, Katrina P Winter, Cynthia A Toth y Sina Farsiu. Segmentación automática validada de la patología AMD, incluidas las drusas y la atrofia geográfica en imágenes SD-OCT. *Oftalmología investigativa y ciencia visual*, 53(1):53–61, 2012.
- [9] Sergio Baamonde, Joaquim de Moura, Jorge Novo y Marcos Ortega. Detección automática de membrana epirretiniana en imágenes de OCT mediante patrones de luminosidad local. En *Conferencia Internacional de Trabajo sobre Redes Neuronales Artificiales*, páginas 222–235. Springer, 2017.
- [10] Joaquim de Moura, Jorge Novo, Pablo Charlón, Noelia Barreira y Marcos Ortega. Visualización mejorada de la vasculatura retiniana utilizando información de profundidad en OCT. *Ingeniería médica y biológica e informática*, 55(12):2209–2225, 2017.
- [11] Gabriela Samagaio, Aída Estévez, Joaquim de Moura, Jorge Novo, María Isabel Fernández y Marcos Ortega. Identificación y Caracterización Automática de Edema Macular Utilizando Imágenes OCT. *Programas y Métodos Informáticos en Biomedicina*, 2018.
- [12] Khaled Alsaih, Guillaume Lemaitre, Mojdeh Rastgoo, Joan Massich, Désiré Sidibé y Fabrice Meriaudeau. Técnicas de aprendizaje automático para la clasificación del edema macular diabético (DME) en imágenes SD-OCT. *ingeniería biomédica en línea*, 16(1):68, 2017.
- [13] Pratul P Srinivasan, Leo A Kim, Priyatham S Mettu, Scott W Cousins, Grant M Comer, Joseph A Izatt y Sina Farsiu. Detección totalmente automatizada de edema macular diabético y degeneración macular seca relacionada con la edad a partir de imágenes de tomografía de coherencia óptica. *Óptica biomédica express*, 5(10):3568–3577, 2014.
- [14] Yu Wang, Yaonan Zhang, Zhaomin Yao, Ruixue Zhao y Fengfeng Zhou. Detección basada en aprendizaje automático de degeneración macular relacionada con la edad (AMD) y edema macular diabético (DME) a partir de imágenes de tomografía de coherencia óptica (OCT). *Óptica biomédica express*, 7(12):4928–4940, 2016.
- [15] Md Akter Hussain, Alauddin Bhuiyan, Chi D Luu, R Theodore Smith, Robyn H Guymer, Hiroshi Ishikawa, Joel S Schuman y Kotagiri Ramamohanarao. Clasificación de retina sana y enferma usando SD-Imágenes OCT y algoritmo Random Forest. *Más uno*, 13(6):e0198281, 2018.
- [16] Sri Phani Krishna Karri, Debjani Chakraborty y Jyotirmoy Chatterjee. Transferir la clasificación basada en el aprendizaje de imágenes de tomografía de coherencia óptica con edema macular diabético y degeneración macular seca relacionada con la edad. *Óptica biomédica express*, 8(2):579–592, 2017.
- [17] Muhammad Awais, Henning Müller, Tong B Tang y Fabrice Meriaudeau. Clasificación de imágenes SD-OCT utilizando un enfoque de aprendizaje profundo. En *Aplicaciones de procesamiento de señales e imágenes (ICSIPA), Conferencia internacional IEEE 2017 sobre*, páginas 489–492. IEEE, 2017.
- [18] Genevieve CY Chan, Awais Muhammad, Syed AA Shah, Tong B Tang, Cheng-Kai Lu y Fabrice Meriaudeau. Transferencia de aprendizaje para la detección del edema macular diabético (DME) en imágenes de tomografía de coherencia óptica (OCT). En *Aplicaciones de procesamiento de señales e imágenes (ICSIPA), Conferencia internacional IEEE 2017 sobre*, páginas 493–496. IEEE, 2017.
- [19] Weibo Liu, Zidong Wang, Xiaohui Liu, Nanyin Zeng, Yurong Liu y Fuad E Alsaadi. Un estudio de las arquitecturas de redes neuronales profundas y sus aplicaciones. *neurocomputación*, 234:11–26, 2017.
- [20] Alex Krizhevsky, Ilya Sutskever y Geoffrey E. Hinton. Clasificación de Imagenet con redes neuronales convolucionales profundas. En *Avances en los sistemas de procesamiento de información neuronal*, páginas 1097–1105, 2012.
- [21] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li y Li Fei-Fei. Imagenet: Una base de datos de imágenes jerárquicas a gran escala. En *Computer Vision and Pattern Recognition, 2009. CVPR 2009. Conferencia IEEE sobre*, páginas 248–255. Iee, 2009.
- [22] Karen Simonyan y Andrew Zisserman. Redes convolucionales muy profundas para el reconocimiento de imágenes a gran escala. *preimpresión de arXiv arXiv:1409.1556*, 2014.
- [23] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jon Shlens y Zbigniew Wojna. Repensando la arquitectura inicial para la visión artificial. En *Actas de la conferencia IEEE sobre visión artificial y reconocimiento de patrones*, páginas 2818–2826, 2016.
- [24] Alan Jović, Karla Brkić y Nikola Bogunović. Una revisión de los métodos de selección de características con aplicaciones. En *Tecnologías de la Información y la Comunicación, Electrónica y Microelectrónica (MIPRO), 2015 38 Convención Internacional sobre*, páginas 1200–1205. IEEE, 2015.
- [25] Mark A Hall y Lloyd A Smith. Selección práctica de subconjuntos de funciones para el aprendizaje automático. En *Actas de informática 98 de la 21.ª conferencia de informática de Australasia ACSC*, volumen 98, páginas 181–191, 1998.
- [26] Mark Andrew Pasillo. Selección de características basada en la correlación para el aprendizaje automático. 1999.
- [27] Kenji Kira y Larry A. Rendell. Un enfoque práctico para la selección de características. En *Procedimientos de aprendizaje automático 1992*, páginas 249–256. Elsevier, 1992.
- [28] Marko Robnik-Šikonja y Igor Kononenko. Análisis teórico y empírico de ReliefF y RReliefF. *Aprendizaje automático*, 53(1-2):23–69, 2003.
- [29] Hong Zeng y Yiu-ming Cheung. Selección de funciones y aprendizaje del núcleo para la agrupación en clústeres basada en el aprendizaje local. *Transacciones IEEE en patrón análisis e inteligencia de máquina*, 33(8):1532–1547, 2011.
- [30] Dmitriy Fradkin e Ilya Muchnik. Máquinas vectoriales de soporte para la clasificación. *Serie DIMACS en Matemática Discreta e Informática Teórica*, 70:13–20, 2006.
- [31] Raof Gholami y Nikoo Fakhari. Máquina de vectores de soporte: principios, parámetros y aplicaciones. En *Manual de Computación Neural*, páginas 515–535. Elsevier, 2017.